# LAPORAN TEKNIS DATA ENGINEERING & NLP (RQ1)

*Ekstraksi, Pembersihan, dan Pemodelan Wacana Digital Multi-Platform Terkait Isu Papua & Identitas Kemelanesiaan di Kawasan ASEAN*

| | |
|---|---|
| **Peran Tim Pelaksana** | Tim IT / Computer Science (Spesialisasi: Data Engineering & NLP) |
| **Lingkup Pekerjaan (Job Desk)** | Research Question 1 (RQ1) - Analisis Sentimen & Entman Framing Digital |
| **Dokumen Rujukan Utama** | Panduan Penelitian Kolaboratif (MABA SCOPUS.pdf) |
| **Total Korpus Terproses** | 1.571 Data Multi-Platform (X: 375, YouTube: 884, Berita Online: 312) |

## 1. Pendahuluan & Batasan Peran Teknis

Laporan teknis ini disusun oleh Tim IT sebagai bentuk pertanggungjawaban penyelesaian Research Question 1 (RQ1) dalam kerangka riset multidisiplin publikasi jurnal Scopus FISIP. Sesuai pembagian keahlian, tugas utama bidang IT berfokus secara eksklusif pada rekayasa data (data engineering), penarikan data digital (web crawling/scraping), pembersihan data (noise filtering), pemodelan Natural Language Processing (NLP), serta anotasi komputasional terhadap sentimen dan kategori framing wacana.

Laporan ini secara ketat menyajikan data statistik deskriptif dan temuan awal komputasional (preliminary computational findings). Laporan ini TIDAK membuat klaim kausalitas sosial-politik, evaluasi keberhasilan kebijakan pemerintah, maupun interpretasi substantif Hubungan Internasional yang berada di luar batas kompetensi bidang IT. Analisis penerimaan publik pada RQ2 akan dilanjutkan oleh Tim Sosiologi melalui metode survei panel, sementara sintesis efektivitas diplomasi luar negeri pada RQ3 akan dianalisis oleh Tim Hubungan Internasional.

## 2. Rekapitulasi Progres Teknis Berdasarkan Jejak Direktori Proyek

• **Folder 0_data/**: Penyimpanan data mentah awal dan seluruh berkas CSV hasil scraping multi-platform yang terstandarisasi.

• **Folder 1_scraping/**: Eksperimen awal penarikan data tuitan dari Platform X (Twitter) menggunakan library twikit.

• **Folder 2 & 3_hasil1_x/**: Iterasi pertama pemodelan sentimen pada data X untuk menguji baseline performa model komputasional.

• **Folder 4_hasil2_x/**: Evaluasi teknis terhadap hasil klasifikasi sentimen awal iterasi pertama.

• **Folder 5, 6, & 7_hasil4_x/**: Iterasi kedua NLP X: Implementasi model Pretrained Twitter-RoBERTa, Context-Aware Adjustment, dan Opsi 1 Rigorous Geoclustering (375 tuitan bersih bebas bias geolokasi).

• **Folder 8_multiplatform_scraping/**: Arsitektur scraping multi-platform: Pembangunan scraper YouTube (registry 30 video berita regional) dan evaluasi teknis platform Reddit.

• **Folder 9 & 10_hasil5_yt/**: Pipeline NLP sentimen dan Entman Framing untuk komentar YouTube berita regional (884 komentar terverifikasi dari CNA, Astro Awani, ABC News, RNZ, dan Al Jazeera).

• **Folder 11_media_berita_scraping/**: Pembangunan crawler & scraper portal media berita online menggunakan Google News RSS, GoogleNewsDecoder, dan BeautifulSoup4 (312 artikel penuh).

• **Folder 12 & 13_hasil_news/**: Pipeline NLP media berita online menerapkan metode Inverted Pyramid Lead Paragraph Processing (312 artikel teranalisis sentimen dan framing-nya).

• **Folder 14_laporan_dan_master_dataset/**: Folder final serah-terima: Berisi Master Triangulation Dataset (1.571 baris data terpadu), Laporan Teknis Resmi (DOCX dan PDF).

## 3. Metodologi Pengambilan Data (Sampling Strategy)

**a. Kriteria Inklusi Entitas Mutlak**: Setiap data diwajibkan memuat minimal satu entitas inti topik: ['papua', 'west papua', 'papua barat', 'melanesia', 'melanesian', 'ulmwp']. Kueri pencarian dikombinasikan dengan istilah diplomasi dan kedaulatan.

**b. Penargetan Sumber Terverifikasi**: Untuk YouTube dan Media Berita, data diambil secara terfokus dari portal berita arus utama di Singapura (CNA, Straits Times), Malaysia (The Star, FMT, NST, Astro Awani), Kawasan Pasifik (RNZ Pacific, ABC News), dan Mitra Global (Al Jazeera).

**c. Filter Anti-Noise & Pembersihan**: 1) Eksklusi Bencana Alam Murni: Seluruh artikel gempa bumi/tsunami tanpa konteks diplomasi/konflik disaring dan dibuang otomatis. 2) Eksklusi Flame War & Spam antarnetizen.

## 4. Metodologi Komputasional & Spesifikasi Model NLP

**a. Arsitektur Model Transformer**: Menggunakan model pretrained 'cardiffnlp/twitter-roberta-base-sentiment-latest' dari Hugging Face Transformers untuk menangkap konteks semantik wacana.

**b. Penajaman Kontekstual Hubungan Internasional**: Menggunakan aturan leksikal pelengkap di mana desakan HAM/tuduhan kolonialisme dilabeli kritis/negatif terhadap posisi RI, dan narasi pembangunan/kedaulatan dilabeli positif.

**c. Pendekatan Inverted Pyramid untuk Berita**: Menganalisis judul + lead paragraph (250 kata pertama) untuk inferensi sentimen model transformer, serta keseluruhan teks untuk framing.

**d. Operasionalisasi Entman Framing**: 5 dimensi (HAM & Pelanggaran Kemanusiaan, Identitas Melanesia & Pasifik, Kedaulatan & Penentuan Nasib Sendiri, Pembangunan & Stabilitas Keamanan, Diplomasi & Hubungan Internasional).

**e. Library yang Digunakan**: Transformers, PyTorch, GoogleNewsDecoder, BeautifulSoup4, Twikit, Pandas, NumPy, Matplotlib, Seaborn, WordCloud, Tqdm.

## 5. Temuan Awal Data Komputasional (Preliminary Findings)

Distribusi statistik deskriptif dari 1.571 total data wacana digital yang terangkum dalam berkas master_triangulation_asean_papua.csv:

### Tabel 1: Sebaran per Platform Digital

| Platform Digital | Jumlah Sampel Bersih | Persentase (%) |
|---|---|---|
| YouTube Comments (Komentar Berita Video) | 884 | 56.27% |
| Platform X / Twitter (Opini Publik/Aktivis) | 375 | 23.87% |
| Media Berita Online (Teks Berita Resmi) | 312 | 19.86% |

### Tabel 2: Sebaran per Blok Geopolitik

| Blok Geopolitik | Jumlah Data | Persentase (%) |
|---|---|---|
| Mitra Global (Al Jazeera, Komunitas Internasional) | 750 | 47.74% |
| Blok ASEAN (Singapura, Malaysia, dan Regional) | 493 | 31.38% |
| Blok Pasifik & Melanesia (RNZ, ABC News, Pasifik) | 287 | 18.27% |
| Wacana Regional Non-Spesifik | 41 | 2.61% |

### Tabel 3: Distribusi Sentimen Teranotasi

| Kategori Sentimen Teranotasi | Jumlah Data | Persentase (%) |
|---|---|---|
| Netral (Faktual / Diskusi Berimbang) | 757 | 48.19% |
| Negatif (Kritis terhadap Posisi/Diplomasi RI) | 650 | 41.37% |
| Positif (Mendukung Pembangunan/Kedaulatan RI) | 164 | 10.44% |

### Tabel 4: Distribusi Kategori Entman Framing

| Kategori Framing Narasi (Entman) | Jumlah Data | Persentase (%) |
|---|---|---|
| Diplomasi & Hubungan Internasional | 569 | 36.22% |
| HAM & Pelanggaran Kemanusiaan | 469 | 29.85% |
| Pembangunan & Stabilitas Keamanan | 203 | 12.92% |
| Identitas Melanesia & Solidaritas Pasifik | 191 | 12.16% |
| Kedaulatan & Penentuan Nasib Sendiri | 139 | 8.85% |

## 6. Catatan Teknis Serah-Terima untuk Tim Sosiologi & Hubungan Internasional

• **Bagi Tim Sosiologi (Bahan Penanganan RQ2)**: Data sebanyak 493 unit wacana Blok ASEAN (termasuk 316 komentar penonton media Singapura/Malaysia dan 151 artikel berita regional) telah memetakan 5 narasi dominan yang nyata di ruang publik. Tim Sosiologi dapat menggunakan 5 kategori narasi ini sebagai dasar operasionalisasi indikator kuesioner survei kepada 100 responden attentive public per negara (Singapura dan Malaysia) melalui platform survei panel (Populix/Dynata).

• **Bagi Tim Hubungan Internasional (Bahan Penanganan RQ3)**: Data komparasi lintas blok menunjukkan variasi persepsi yang sangat tajam antara media Blok ASEAN (yang menghormati integritas teritorial dan norma non-interference) berhadapan dengan media Blok Pasifik (yang menyoroti tuntutan keanggotaan penuh ULMWP di MSG dan resolusi PBB). Temuan distribusi ini menyediakan basis bukti empiris bagi Tim HI dalam menyusun sintesis evaluasi diplomasi luar negeri RI.

## 7. Penutup, Akses Berkas, & Kesiapan Iterasi Lanjutan

Seluruh data bersih teranotasi tersimpan secara terpusat pada file 'master_triangulation_asean_papua.csv' di folder 14_laporan_dan_master_dataset/. Tahap awal pengumpulan data dan pemodelan komputasional RQ1 ini telah tuntas disiapkan sebagai fondasi empiris awal riset. Tim IT tetap siap dan terbuka untuk melakukan penyesuaian teknis, kalibrasi parameter model, penyaringan tambahan, maupun revisi metodologis sesuai masukan, diskusi, dan arahan dari dosen pembimbing serta rekan tim FISIP (Sosiologi dan Hubungan Internasional) pada tahap berikutnya.