LAPORAN AKHIR PROYEK · FINAL PROJECT REPORT

ASEAN–Papua Digital Diplomacy NLP

Laporan pemulihan, evaluasi, dan penutupan teknis pipeline NLP dan dataset pilote 1.540 record. Menyajikan temuan audit kondisi awal, tahapan perbaikan bertahap (M0–M2.1), fresh inference 1.013 record berbahasa Inggris, keterbatasan penelitian, serta daftar keputusan yang menunggu persetujuan tim.

Tim Teknologi Informasi / NLP Engineering · 8 November 2026

REPORT

Daftar Isi

BAB 1 — Pendahuluan 2

1.1 Gambaran umum proyek . . . 2

1.2 Tujuan pekerjaan pemulihan dan evaluasi . . . 2

1.3 Mengapa pipeline dan dataset perlu diaudit . . . 2

BAB 2 — Masalah yang Ditemukan pada Kondisi Awal 3

BAB 3 — Apa Saja yang Telah Dikerjakan 4

3.1 Audit dan evaluasi kondisi awal . . . 4

3.2 Rekonstruksi serta pemulihan dataset . . . 4

3.3 Penyusunan golden baseline M0 . . . 4

3.4 Konfigurasi pipeline M1 . . . 5

3.5 Modularisasi pipeline M2 . . . 5

3.6 Perbaikan keandalan M2.1 . . . 5

3.7 Fresh inference untuk data berbahasa Inggris . . . 5

3.8 Pengujian dan validasi teknis akhir . . . 6

3.9 Dokumentasi dan persiapan handoff . . . 6

3.10 Ringkasan capaian . . . 6

BAB 4 — Apa yang Tidak Dapat Dilakukan atau Belum Dapat Dipastikan 7

4.1 Tidak dilakukan dalam tahap ini . . . 7

4.2 Belum tersedia . . . 7

4.3 Tidak dapat disimpulkan dari data . . . 7

BAB 5 — Keterbatasan Penelitian 8

BAB 6 — Status Akhir dan Rekomendasi untuk Tim 8

6.1 Status akhir . . . 8

6.2 Keputusan yang menunggu tim . . . 8

6.3 Soal Cohen's Kappa . . . 9

6.4 Pembagian tanggung jawab . . . 9

BAB 7 — Penutup 9

Dokumen ini adalah laporan akhir pekerjaan pemulihan (recovery), evaluasi, dan penutupan teknis proyek NLP ASEAN-Papua Digital Diplomacy, disusun untuk anggota tim sosial-humaniora dan dosen pembimbing. Laporan teknis mendetail tersedia dalam berkas terpisah di folder docs/ repositori.

BAB 1 — Pendahuluan

1.1 Gambaran umum proyek

Proyek ASEAN-Papua Digital Diplomacy NLP adalah bagian dari riset kolaboratif multidisiplin yang mengkaji bagaimana isu Papua dan klaim identitas Melanesia Indonesia dibicarakan di ruang digital internasional. Sebagai penjelasan sederhana: proyek ini mengumpulkan ribuan tulisan publik dari tiga sumber daring — unggahan di platform X (Twitter), komentar di bawah video berita YouTube, dan artikel media berita daring dari Malaysia, Singapura, kawasan Pasifik, dan media global — kemudian mengolahnya secara otomatis dengan bantuan model kecerdasan buatan untuk mengelompokkan nada pembicaraan (positif, netral, negatif) dan tema yang dibicarakan (hak asasi manusia, kedaulatan, identitas Melanesia, pembangunan, dan diplomasi).

Bagian teknologi informasi bertugas membangun dan merawat "mesin pengolah teks" tersebut, memastikan datanya dapat dipercaya, serta menyerahkan hasilnya kepada tim Sosiologi dan Hubungan Internasional untuk dianalisis lebih lanjut. Laporan ini mendokumentasikan bagaimana mesin tersebut diaudit, diperbaiki, diuji ulang, dan disiapkan untuk diserahkan.

1.2 Tujuan pekerjaan pemulihan dan evaluasi

Pada akhir tahun 2026 dilakukan audit menyeluruh terhadap pipeline (urutan proses pengolahan data) dan dataset yang ada. Audit menemukan sejumlah masalah serius — mulai dari daftar pustaka yang memuat rujukan yang tidak pernah ada, hingga aturan klasifikasi yang secara diam-diam mengubah hasil analisis. Tujuan pekerjaan berikutnya adalah: (1) memperbaiki apa yang dapat diperbaiki tanpa mengubah data mentah, (2) mendokumentasikan dengan jujur apa yang belum dapat dipastikan, (3) membekukan hasil yang sudah benar sebagai acuan (baseline), dan (4) menyerahkan semuanya dalam kondisi yang dapat diuji ulang oleh siapa pun.

1.3 Mengapa pipeline dan dataset perlu diaudit

Riset yang berbasis analisis teks otomatis hanya dapat dipertanggungjawabkan jika tiga hal terjamin: data yang masuk benar-benar relevan, proses pengolahannya jujur dan dapat diulang, serta klaim yang keluar tidak melebihi bukti yang ada. Audit dilakukan karena temuan awal menunjukkan ketiganya belum terpenuhi — misalnya, sebagian besar label analisis ternyata dihasilkan oleh aturan kata-kunci buatan tangan, bukan oleh model kecerdasan buatan yang diklaim; dan sebagian besar lokasi geografis akun diperkirakan dari kata-kata di dalam tulisan, bukan dari data profil yang sebenarnya. Tanpa pemulihan, hasil riset berisiko dikritik bahkan ditolak oleh penelaah jurnal internasional.

BAB 2 — Masalah yang Ditemukan pada Kondisi Awal

Audit awal memeriksa 27 rujukan pustaka, seluruh kode pipeline, tiga dataset mentah, dan dataset gabungan berisi 1.571 baris. Berikut masalah-masalah utama yang ditemukan, dengan contoh konkret:

Bidang masalah	Temuan audit (contoh nyata)
Rujukan pustaka	6 dari 27 rujukan tidak dapat diverifikasi keberadaannya (gelar, nama jurnal, dan halaman tidak pernah ada); 4 lagi salah tulis penulis/judul/tahun; klaim kualitas terjemahan “BLEU di atas 85” tidak didukung literatur mana pun (angka realistis sistem terbaik sekitar 40–50)
Klaim vs implementasi	Naskah menyebut penerjemahan otomatis, deteksi bahasa, dan pengukuran kesepakatan anotator (κ minimal 0,75) — padahal ketiganya tidak pernah dijalankan dalam kode; 117 dari 375 tuitan berbahasa Indonesia diproses langsung oleh model berbahasa Inggris tanpa penerjemahan
Model sentiment analysis	Model yang dipakai hanya mendukung bahasa Inggris (sesuai dokumentasi resminya), sehingga teks bahasa Indonesia yang tidak diterjemahkan menghasilkan pola tidak wajar: 278 dari 282 baris berlabel “Neutral”
Aturan kata-kunci (rule layer)	Aturan buatan tangan mengubah 396 dari 1.571 label model (25,2%); 297 dari itu berubah dari “netral” menjadi “negatif” — artinya hampir separuh temuan “wacana kritis” dibentuk oleh daftar kata, bukan oleh model; aturan juga salah arah, misalnya kalimat pro-pemerintah yang menyebut kata “referendum” ikut dilabeli kritis
Framing	Pipeline X dan YouTube hanya memiliki 4 kategori bingkai, bukan 5; 508 dari 569 baris berlabel “Diplomasi & Hubungan Internasional” sesungguhnya adalah baris tanpa kecocokan kata kunci apa pun yang dipetakan diam-diam ke label tersebut
Geolokasi	Pencocokan lokasi berbasis potongan kata (substring): “Den Haag, Nederland” terbaca sebagai Laos (karena huruf “la” di dalam “Nederland”); 120 dari 172 baris X berblok “Mitra Global” terpicu hanya oleh potongan seperti “un” atau “uk” di dalam kata lain; lokasi YouTube memakai negara kanal video, bukan negara komentator
Tanggal, bahasa, sumber	Artikel berita rentang 2008–2026 dicampur tanpa stratifikasi; 4 artikel bertanggal hari pengambilan data karena kegagalan baca tanggal; YouTube hanya menyimpan waktu relatif (“7 tahun lalu”) sehingga analisis waktu mustahil; 59,7% komentar YouTube berasal dari satu kanal (Al Jazeera)
Reproduksibilitas	Master dataset tidak dapat dihasilkan ulang dari kode mana pun yang tersedia (label baris X dibuat oleh pipeline yang tidak ikut disimpan); tidak ada satu pun pengukuran akurasi berbasis pembanding berlabel manusia

Tabel 2.1 — Ringkasan temuan audit kondisi awal

Satu hal penting untuk disampaikan: seluruh masalah di atas adalah masalah proses dan dokumentasi, bukan bukti niat buruk. Dataset mentahnya sendiri utuh dan dapat dipercaya keberadaannya; yang bermasalah adalah cara mengolah dan cara mengklaimnya.

BAB 3 — Apa Saja yang Telah Dikerjakan

Pekerjaan pemulihan dilakukan bertahap dalam sembilan kelompok besar. Setiap tahap diakhiri dengan pengujian otomatis agar perbaikan berikutnya tidak merusak hasil sebelumnya.

3.1 Audit dan evaluasi kondisi awal

masalah awal: Belum diketahui seberapa besar kesenjangan antara klaim dokumen dan kenyataan kode.

tindakan: Pemeriksaan baris demi baris terhadap seluruh kode, dataset, dan 27 rujukan; verifikasi rujukan ke katalog penerbit dan indeks akademik.

hasil: Daftar masalah terkuantifikasi (lihat Tabel 2.1) dengan tingkat keparahan dan lokasi berkas.

manfaat: Tim mengetahui dengan pasti apa yang salah dan di mana, sehingga perbaikan tidak menebak-nebak.

3.2 Rekonstruksi serta pemulihan dataset

masalah awal: Label analisis tidak dapat dilacak asal-usulnya; lokasi geografis salah; baris duplikat dan tidak relevan bercampur.

tindakan: Pipeline diperbaiki: pencocokan lokasi berbasis batas kata (word boundary), pemisahan variabel asal-penulis dan topik-yang-dibahas, label model dan label aturan dipisahkan ke kolom berbeda dengan bukti kata-kunci, filter duplikat/spam diterapkan dengan alasan eksplisit per baris.

hasil: Master dataset baru berisi 1.540 baris retained (dikecualikan 83 dengan alasan tercatat, 31 Reddit ditandai untuk ditinjau); 92,9% baris lolos tanpa perubahan konten teks.

manfaat: Setiap angka kini dapat dijelaskan asal-usulnya per baris; data mentah tidak pernah diubah.

3.3 Penyusunan golden baseline M0

masalah awal: Tanpa acuan beku, perbaikan berikutnya tidak bisa dibuktikan tidak merusak hasil.

tindakan: 1.540 baris dikunci sebagai baseline emas (19 kolom, dicatat SHA-256 dan manifest), dilengkapi prosedur regresi otomatis.

hasil: Baseline emas SHA-256 4e2cf764... yang tetap tidak berubah sampai laporan ini ditulis.

manfaat: Setiap perubahan ke depan dapat dibuktikan “zero pergeseran semantik” terhadap acuan yang sama.

3.4 Konfigurasi pipeline M1

masalah awal: Daftar kata kunci, ambang bahasa, dan identitas model tertanam di dalam kode — rawan berubah diam-diam.

tindakan: Seluruh konfigurasi dipindahkan verbatim ke berkas YAML di folder configs/ dengan pemuat yang menolak konfigurasi cacat.

hasil: 118 pengujian tetap lulus; regresi emas membuktikan nol pergeseran; satu sumber konfigurasi tunggal.

manfaat: Perubahan ke depan menjadi keputusan yang terlihat dan dapat ditinjau tim, bukan suntingan diam-diam.

3.5 Modularisasi pipeline M2

masalah awal: Seluruh logika menumpuk di beberapa skrip besar sehingga sulit diuji per bagian.

tindakan: Pipeline dipecah menjadi modul-modul bertanggung jawab jelas (pembersihan, deteksi bahasa, antarmuka terjemahan yang memang dimatikan, sentiment, stance, framing, orkestrator baris perintah) dengan manifest per tahap.

hasil: Setiap tahap dapat dijalankan dan diuji sendiri-sendiri; entry point lama tetap berfungsi.

manfaat: Pemeliharaan dan audit ke depan jauh lebih murah dan aman.

3.6 Perbaikan keandalan M2.1

masalah awal: Audit independen menemukan kegagalan eksekusi bisa meninggalkan berkas hasil lama yang menyesatkan, manifest gagal tidak lengkap, dan kosakata label campur pada tahap stance.

tindakan: Tiga perbaikan diterapkan dan diuji empiris: hasil lama dihapus saat eksekusi baru dimulai, manifest gagal wajib memuat waktu selesai, dan kosakata label dasar yang tidak cocok ditolak keras.

hasil: 11 tes regresi baru; seluruh jalur gagal kini jujur dan dapat diaudit.

manfaat: Tidak ada lagi artefak menyesatkan yang bisa tertinggal tanpa jejak.

3.7 Fresh inference untuk data berbahasa Inggris

masalah awal: Seluruh 1.407 prediksi lama adalah prediksi historis tanpa catatan versi model; 133 baris tidak punya prediksi sama sekali.

tindakan: Model Cardiff dijalankan sungguhan di lingkungan terverifikasi (Python 3.11, torch 2.15.0+cpu, transformers 5.22.2) atas 1.013 baris berbahasa Inggris; revisi model aktual terekam dari cache Hugging Face.

hasil: 1.013 prediksi baru: Negative 348, Neutral 537, Positive 128; uji determinisme lulus; master dan golden baseline tidak disentuh.

manfaat: Klaim sentiment kini bisa bersandar pada prediksi yang terverifikasi eksekusinya, dengan versi model eksplisit.

3.8 Pengujian dan validasi teknis akhir

masalah awal: Perbaikan bertahap berisiko saling merusak.

tindakan: 118 pengujian otomatis (unit, integrasi, regresi emas, keandalan) dijalankan penuh; integritas hash data mentah, master, dan baseline diverifikasi ulang.

hasil: 118/118 lulus; zero pergeseran semantik; raw data tidak berubah.

manfaat: Keandalan perubahan terbukti, bukan diklaim.

3.9 Dokumentasi dan persiapan handoff

masalah awal: Dokumentasi lama memuat klaim yang melampaui kenyataan.

tindakan: Metodologi ditulis ulang sesuai kenyataan; kamus dataset, register keputusan yang tertunda, dan persyaratan handoff disusun; laporan ini dibuat.

hasil: Paket serah terima lengkap: dataset + kamus + baseline + register keputusan + laporan PDF.

manfaat: Tim penerima dapat memulai dari titik yang jelas tanpa menebak apa yang sudah dan belum dilakukan.

3.10 Ringkasan capaian

Indikator	Sebelum	Sesudah
Rujukan pustaka	6 fabrikan, 4 salah tulis	Semua diganti/terverifikasi, catatan penghapusan terdokumentasi
Geolokasi	Substring salah (Nederland = Laos)	Gazetteer batas kata; 267/375 jujur dilabeli tidak spesifik
Label analisis	Model + aturan tercampur tanpa jejak	Label model dan label aturan dipisah, dengan bukti kata-kunci
Framing	Residual 508 baris dipetakan ke “Diplomasi”	Residual eksplisit “Other/No-Frame” (704 baris) dengan bukti
Reproduksibilitas	Master tak bisa dihasilkan ulang	Satu perintah membangun ulang; 118 tes menjaga perilaku
Prediksi sentiment	1.407 historis tanpa versi; 133 kosong	1.013 prediksi baru terverifikasi + revisi model tercatat
Dokumentasi	Klaim melampaui implementasi	Metodologi sesuai kenyataan + batasan eksplisit

Tabel 3.1 — Perbandingan kondisi awal dan kondisi akhir

BAB 4 — Apa yang Tidak Dapat Dilakukan atau Belum Dapat Dipastikan

Kejujuran laporan ini sama pentingnya dengan daftar pencapaiannya. Tiga kategori dibedakan secara ketat: (a) hal yang memang **tidak dilakukan** dalam tahap ini; (b) hal yang **belum tersedia** karena menunggu keputusan atau sumber daya; (c) hal yang **tidak dapat disimpulkan** dari data yang ada, berapa pun usahanya.

4.1 Tidak dilakukan dalam tahap ini

Pengumpulan data tambahan tidak dilakukan; tidak ada penggantian model; tidak ada penerjemahan otomatis yang dijalankan; tidak ada penyusunan codebook atau keputusan cakupan penelitian — semuanya menunggu keputusan tim (lihat register keputusan).

4.2 Belum tersedia

Sentiment analysis untuk 295 baris berbahasa Indonesia belum memiliki hasil yang dapat dipertanggung-jawabkan dengan model yang dipakai — baris-baris ini sengaja dibiarkan tanpa label baru. Data dengan bahasa tidak teridentifikasi (213 baris) dan 19 baris bahasa lain tidak dapat diperlakukan sebagai cakupan bahasa yang tervalidasi. Belum ada golden standard berlabel manusia, sehingga akurasi, precision, recall, dan F1 model belum dapat dihitung — dan tidak boleh diklaim.

4.3 Tidak dapat disimpulkan dari data

Pertanyaan yang menggoda	Mengapa belum bisa dijawab
Apakah aturan stance dan framing benar-benar menangkap posisi diplomatik dalam teks?	Belum ada pembanding manusia; aturan stance bahkan punya asumsi arah yang terdokumentasi salah (kalimat pro-pemerintah yang menyebut “referendum” ikut dilabeli kritis)
Dari negara mana penulis sebuah tuitan?	Lokasi penulis X tidak terverifikasi untuk 260 dari 364 baris; lokasi YouTube memakai negara kanal video, bukan negara komentator
Kapan persisnya percakapan terjadi?	YouTube hanya menyimpan waktu relatif; sebagian kecil tanggal berita berasal dari tanggal pengambilan data
Apakah data mewakili seluruh masyarakat/negara/opini internasional?	Tidak — korpus adalah sampel purposive terkurasi dengan ketimpangan sumber dan bahasa yang terukur
Bisakah ditarik hubungan sebab-akibat (misalnya “diplomasi gagal karena X”)?	Tidak — data eksploratif deskriptif tanpa desain kausal; penarikan sebab-akibat tidak sah dari data ini

Tabel 4.1 — Batas inferensi yang wajib dihormati

BAB 5 — Keterbatasan Penelitian

Berikut keterbatasan per dimensi, disertai implikasinya terhadap cara membaca hasil. Keterbatasan ini bukan alasan membuang data — melainkan syarat agar data digunakan pada pertanyaan yang tepat.

Dimensi	Keterbatasan	Implikasi interpretasi
1. Sampel & representativitas	Korpus purposive terkurasi N=1.540; target 3.000–5.000 belum tercapai	Hasil menggambarkan percakapan yang tertangkap, bukan opini populasi; jangan klaim representatif
2. Bahasa	Hanya Inggris+Indonesia terukur; Melayu/Prancis nol; 213 baris und	Suara non-Inggris/non-Indonesia (mis. Kaledonia Baru berbahasa Prancis) tidak terekam
3. Platform & sumber	59,7% komentar YouTube dari satu kanal; sebagian outlet terdaftar bernilai nol	Perbandingan antar-sumber hanya sah untuk outlet dengan n memadai
4. Model sentiment	Model Inggris-saja; domain tweet dipakai untuk lead berita tanpa pengukuran pergeseran domain	Label sentiment EN sah sebagai keluaran model pada domain ini, bukan kebenaran nada pembicaraan
5. Pengukuran stance & framing	Rule layer eksperimental dengan asumsi arah; framing = topic salience leksikal	Jangan laporkan sebagai “stance terverifikasi” atau “framing Entman”
6. Informasi geografis	260/364 baris X tanpa asal terverifikasi; YT = kohort kanal	Analisis lintas negara X tidak sah; analisis YT dibaca sebagai kohort penonton kanal
7. Dimensi waktu	YouTube relatif saja; 4 tanggal berita = tanggal scraping; rentang 18 tahun	Analisis tren waktu terbatas pada X dan berita, dengan hati-hati
8. Validasi & anotasi	Tidak ada anotasi manusia; κ tidak diwajibkan tim	Semua angka = eksploratif; klaim akurasi dilarang sampai anotasi ada
9. Generalisasi	Satu isu, satu periode pengambilan, sampel kecil	Temuan berlaku pada korpus ini; ekstrapolasi ke populasi tidak didukung

Tabel 5.1 — Matriks keterbatasan dan implikasinya

BAB 6 — Status Akhir dan Rekomendasi untuk Tim

6.1 Status akhir

Pekerjaan teknik dan dokumentasi pipeline telah mencapai tahap **closure**: pipeline modular dapat dijalankan ulang satu perintah, 118 pengujian otomatis menjaga perilakunya, dataset dan baseline emas dibekukan dengan hash, dan seluruh keputusan teknis terekam. Dataset dan artefak yang ada dapat dipakai sebagai titik awal analisis lanjutan — dengan batasan yang dijelaskan pada Bab 4 dan Bab 5.

6.2 Keputusan yang menunggu tim

Pertanyaan-pertanyaan penelitian berikut sengaja dibiarkan terbuka dan didokumentasikan dalam register keputusan (`docs/PENDING_DECISIONS_REGISTER.md`): rumusan final RQ1 (tiga formulasi masih terdokumentasi); pilihan cakupan (ASEAN saja vs internasional terkurasi — rekomendasi kelayakan:

internasional terkurasi); periode pengambilan data; strategi bahasa dan terjemahan; codebook stance (target/proposisi dan unit analisis) serta codebook framing; jumlah anotator dan ukuran sampel anotasi; dan keluaran RQ1 mana yang boleh dipakai sebagai bahan RQ2/RQ3.

6.3 Soal Cohen's Kappa

Sesuai keputusan tim tanggal 8 November 2026, Cohen's Kappa tidak dijadikan syarat penyelesaian proyek. Konsekuensinya dijelaskan berjenjang: bila dua anotator independen tersedia, nilai κ dilaporkan apa adanya; bila hanya satu anotator, labelnya dicatat sebagai referensi terbatas satu-anotator dan perbandingan model terhadapnya wajib menyebut keterbatasan itu; bila tidak ada anotasi sama sekali, seluruh hasil harus diposisikan sebagai analisis eksploratif-deskriptif dan tidak boleh ada klaim kinerja model yang tervalidasi.

6.4 Pembagian tanggung jawab

Tanggung jawab	Pemilik
Pipeline, pengujian, manifest, reproduksibilitas, dokumentasi keterbatasan	Pemilik engineering (diserahkan)
Persetujuan cakupan penelitian dan rumusan final RQ1	Tim peneliti
Rekrutmen anotator dan pelaksanaan anotasi	Tim peneliti
Codebook framing dan target stance (konstruk teoretis)	Tim Hubungan Internasional
Interpretasi sosiologis dan hubungan internasional atas hasil	Tim Sosiologi / HI
Keputusan pengumpulan data tambahan	Tim peneliti

Tabel 6.1 — Pembagian tanggung jawab pasca-handoff

BAB 7 — Penutup

Proyek ini melalui perjalanan yang jujur: dimulai dari pipeline yang bekerja tetapi belum dapat dipertanggungjawabkan, melewati audit yang menemukan masalah-masalah serius, hingga tiba pada kondisi sekarang — sebuah pipeline modular dengan 118 pengujian otomatis, dataset pilote 1.540 baris yang setiap labelnya dapat dilacak asal-usulnya, 1.013 prediksi sentiment baru yang eksekusinya terverifikasi, dan dokumentasi yang tidak mengklaim lebih dari yang dibuktikan.

Yang telah dipulihkan adalah fondasinya: data yang dapat dijelaskan, proses yang dapat diulang, dan batas-batas yang dinyatakan terbuka. Yang belum selesai — validasi manusia, keputusan cakupan, dan pengayaan data — bukan kegagalan teknik, melainkan pekerjaan penelitian yang memang milik tim. Dengan paket handoff ini, langkah berikutnya berada di tangan peneliti sosial-humaniora: menentukan arah pertanyaan, menyediakan pembanding manusia, dan menimbang klaim yang layak diajukan.

Seluruh berkas rujukan laporan ini tersimpan di repositori proyek pada folder docs/ dan data/, dengan catatan integritas (SHA-256) pada setiap manifest terkait. Tanggal penutupan: 8 November 2026.

— Tim Teknologi Informasi / NLP Engineering —